

Εργασία 1

Παράλληλα και Διανεμημένα Συστήματα

Φραιδάκης Ιωάννης (email: fraidaki@ece.auth.gr , AEM : 10736)

11/11/2024

Εισαγωγή

Σκοπός της εργασίας είναι η συγγραφή κώδικα στη γλώσσα C για την προσεγγιστική εύρεση των k κοντινότερων γειτόνων (approximate-k-nearest-neighbors / ANN) ενός συνόλου Q σημείων/ερωτημάτων (*query-set*) ως προς ένα σύνολο C δεδομένων σημείων (*corpus-set*), διάστασης d και κατόπιν βελτιστοποίησής του χρησιμοποιώντας τεχνικές παράλληλου προγραμματισμού. Η προσεγγιστική εύρεση των k κοντινότερων γειτόνων στοχεύει στην εξισορρόπηση μεταξύ ταχύτητας και ακρίβειας, ιδίως όταν η ακριβής εύρεση των γειτόνων (knn) καθίσταται υπολογιστικά απαγορευτική λόγω μεγάλου πλήθους δεδομένων ή διαστάσεων. Θα εστιάσουμε στην περίπτωση όπου $C=Q$ (με δυνατότητα εύκολης επέκτασης στη γενικότερη περίπτωση). Τέλος, θα προσπαθήσουμε να βρούμε την χρυσή τομή για το tradeoff μεταξύ ταχύτητας επεξεργασίας (queries per second) και ποσοστό ακρίβειας (recall).

Προτεινόμενος αλγόριθμος

Διαμερίζουμε το Q αναδρομικά σε διακριτά υποσύνολα έως ότου καθένα απ' αυτά έχει μέγεθος το πολύ **MIN_SIZE**. Για κάθε τέτοιο υποσύνολο υπολογίζουμε τους ακριβείς knn του και κατόπιν “ενώνουμε” (merge) τις επιμέρους λύσεις. Έστω λοιπόν $Q1$, $Q2$ δύο προς ένωση υποσύνολα (με $Q1 \cap Q2 = \emptyset$). Ο τρόπος που γίνεται το merging είναι ο εξής : Επιλέγουμε **sample_size**, σε πλήθος, τυχαία σημεία από το $Q1$ για τα οποία βρίσκουμε τους ακριβείς knn στο $Q1 \cup Q2$ υπολογίζοντας τις ευκλείδειες αποστάσεις με όλα τα σημεία του $Q2$ (με τα σημεία του $Q1$ έχουν γίνει ήδη οι υπολογισμοί από το base case της αναδρομής). Για καθένα από τα εναπομείναντα σημεία του $Q1$ (non-sampled), βρίσκουμε τα **N** πλησιέστερα δειγματοληπτημένα σημεία σ' αυτό. Χρησιμοποιώντας τους knn των N sampled points, δημιουργούμε ένα σύνολο υποψήφιων προς εξέταση σημείων ($N*k$ στο σύνολο). Εξετάζουμε κάθε τέτοιο υποψήφιο σημείο και ενημερώνουμε κατάλληλα τους knn . Η ίδια διαδικασία επαναλαμβάνεται για το $Q2$.

Υλοποίηση

Σειριακή (μη προσεγγιστική)

Αρχίζουμε υλοποιώντας την «**σειριακή**» μη προσεγγιστική εκδοχή (task V0) προκειμένου να έχουμε μια βάση στον κώδικα αλλά και στα αποτελέσματα (benchmarks) ώστε να μπορεί να γίνει μετέπειτα σύγκριση των ακριβών (non-approximate) αποτελεσμάτων με τις προσεγγιστικές παραλλαγές του, τόσο ως προς το χρόνο εκτέλεσης όσο και για την εύρεση του πλήθους σωστών γειτόνων (recall). Να τονίσουμε σ' αυτό το σημείο ότι για τον υπολογισμό των αποστάσεων γίνεται χρήση συναρτήσεων από τη βιβλιοθήκη OpenBLAS, οι οποίες εκτελούνται σε πολλαπλά νήματα, με τον υπόλοιπο κώδικα όμως να παραμένει σειριακός.

Παράλληλη (προσεγγιστική)

Μετατρέπουμε τον σειριακό αλγόριθμο στον προσεγγιστικό και ξεκινάμε με την **OpenCilk** καθώς έτσι μπορούμε να καταλάβουμε άμεσα και εύκολα ποια κομμάτια αξίζουν να παραλληλοποιηθούν. Αυτό συμβαίνει λόγω της αυτόματης κατανομής φόρτου εργασίας και λόγω της εξασφάλισης για το πολύ δύο φορές πιο αργή εκτέλεση από τη βέλτιστη παράλληλη, αξιοποιώντας την έννοια του work stealing. Οπότε, χρησιμοποιώντας το εργαλείο perf των Linux, εντοπίζουμε τα σημεία που προκαλούν καθυστερήσεις (bottlenecks) στην ANN υλοποίηση και τα στάδια που θα ωφελούνταν από τη χρήση πολυνηματικού προγραμματισμού.

Στη συνέχεια, για κάθε αργό σημείο του κώδικα, εξετάζουμε δύο τεχνικές παραλληλοποίησης. Τη δημιουργία νέων νημάτων με `cilk_spawn` και τη χρήση του `cilk_for` για παράλληλους υπολογισμούς εντός των βρόχων. Τα αποτελέσματα είναι συμβατά με τη θεωρία : Η δημιουργία επιπλέον νημάτων (`cilk_spawn`) είναι αποδοτική μόνο στα αναδρομικά στάδια του αλγορίθμου. Για τα υπόλοιπα (ακριβής υπολογισμοί για τα sampled points και merging), η χρήση του `cilk_for` ώστε να επιτύχουμε ταυτόχρονη επεξεργασία των σημείων είναι πιο αποδοτική, λόγω χαμηλότερου overhead.

Τέλος, για τις υλοποιήσεις με OpenMP και Pthreads παραλληλοποιούμε τα ίδια σημεία ως εξής:

OpenMP: Η μόνη διαφορά έγκειται στις εντολές : `cilk_spawn` → `#pragma omp task` , `cilk_sync` → `pragma omp taskwait` , `cilk_for` → `pragma omp parallel for`. Επίσης, ρυθμίζουμε τον scheduler σε dynamic mode για καλύτερο load balancing προσεγγίζοντας αρκετά την επίδοση της OpenCilk.

Pthreads: δημιουργία νέων νημάτων για την αναδρομή γίνεται δυναμικά με έλεγχο μέσω της μεταβλητής `num_threads`, η οποία ανανεώνεται με χρήση της . Η προσομοίωση της λειτουργίας του `cilk_for` επιτυγχάνεται με τεμαχισμό των βρόχων και κατανομής τους σε νήματα, διασφαλίζοντας με αυτό τον τρόπο ισόποσο υπολογιστικό φόρτο ανά νήμα.

Έλεγχος ορθότητας

Αρχικά, ελέγξαμε την ορθότητα της σειριακής υλοποίησης χρησιμοποιώντας τα προϋπολογισμένα δεδομένα (precomputed data) για την περίπτωση όπου $C \neq Q$, επιβεβαιώνοντας ότι ο σειριακός αλγόριθμος παράγει τα αναμενόμενα αποτελέσματα. Στη συνέχεια, χρησιμοποιήσαμε αυτή τη σειριακή υλοποίηση για να υπολογίσουμε τα "ορθά" αποτελέσματα για τη περίπτωση που μελετάμε ($C = Q$), τα οποία αποτέλεσαν τη βάση για την αξιολόγηση των παραλληλοποιημένων υλοποιήσεων.

Για να διασφαλίσουμε την ορθότητα των παραλληλοποιημένων εκδόσεων, ξεκινήσαμε την εκτέλεση καθεμιάς υλοποίησης σε ένα νήμα και στη συνέχεια αυξήσαμε σταδιακά τον αριθμό των νημάτων. Παρατηρήσαμε ότι το ποσοστό recall παρέμενε σταθερό, με τη μόνη διαφοροποίηση να αφορά τους χρόνους εκτέλεσης. Αυτό αποτελεί μια ισχυρή ένδειξη ότι δεν υπάρχουν προβλήματα συγχρονισμού (race conditions) και ανεπιθύμητων επανεγγραφών δεδομένων (data overwrites).

Άλλωστε, κάθε νήμα γράφει σε ξεχωριστές θέσεις μνήμης, αποφεύγοντας με αυτό τον τρόπο την ανάγκη για συγχρονισμό με locks ή mutexes και καθιστώντας συνάμα την υλοποίηση απλούστερη και πιο αποδοτική. Με χρήση του *ThreadSanitizer* (TSan) επιβεβαιώσαμε τις παραπάνω ενδείξεις.

Γενικά

Δεδομένα

Πλήθος σημείων : $10^3 - 10^6$ | Διαστάσεις : $10^1 - 10^3$ | Πλήθος γειτόνων (k) : $2^4 - 2^7$

Λήφθηκαν από [εδώ](#)¹ και συγκεκριμένα είναι τα :

mnist-784 → 70000 σημεία, 784 διαστάσεις, k = 100 γείτονες

fashion-mnist-784 → 70000 σημεία, 784 διαστάσεις, k = 100 γείτονες

Στο report που θα ανέβει στο Github θα περιλαμβάνετε και το

sift-128 → 1010000 σημεία, 128 διαστάσεις, k = 100 γείτονες (απαιτεί πολύ χρόνο για τα πειράματα).

Preprocessing step

Τα δεδομένα έχουν επέκταση αρχείου : hdf5 και καθένα περιέχει το “test” και το “train” dataset. Στα benchmarks χρησιμοποιούμε την ένωση αυτών των δύο συνόλων.

Βελτιστοποιήσεις

Μπορούμε να ελέγχουμε το tradeoff ακρίβειας – ταχύτητας μεταβάλλοντας τις παραμέτρους MIN_SIZE, sample_size (μέσω του sampling_reduction) και N (μέσω του candidate_reduction). Συγκεκριμένα, το MIN_SIZE καθορίζει το ελάχιστο μέγεθος των υποσυνόλων για επεξεργασία, δηλαδή το base case της αναδρομής. Μεγαλύτερες τιμές συνεπάγονται περισσότερους υπολογισμούς και άρα μειωμένο ρυθμό επεξεργασίας αλλά υψηλότερη ακρίβεια. Όσον αφορά το sampling_reduction, καθορίζει το πλήθος των δειγμάτων που θα λάβουμε. Καθώς αυξάνεται, μειώνονται τα δείγματα οπότε έχουμε λιγότερη ακρίβεια και μεγαλύτερη ταχύτητα. Ομοίως, το candidate_reduction επηρεάζει τον αριθμό των δειγματοληπτημένων σημείων προς εξέταση. Για υψηλότερες τιμές, λαμβάνουμε υπόψη λιγότερα σημεία και άρα έχουμε καλύτερο ρυθμό επεξεργασίας αλλά χειρότερη ακρίβεια. Κάνοντας *fine-tuning* στις παραμέτρους, μπορούμε να βρούμε την χρυσή τομή στον παραπάνω συμβιβασμό.

Επίσης, χρησιμοποιήθηκε το εργαλείο *perf* για τον εντοπισμό των cache misses. Με βάση τα αποτελέσματα, εισάγαμε οδηγίες prefetching για δεδομένα που πρόκειται να χρησιμοποιηθούν σε επόμενες επαναλήψεις, μειώνοντας τα cache misses (και χρόνο φόρτωσης από τη μνήμη).

Τέλος, για την αποθήκευση των σημείων του *query-set*, χρησιμοποιήσαμε το προσδιοριστικό τύπου *alignas*. Η χρήση του εξασφαλίζει ότι οι πίνακες δεδομένων είναι ευθυγραμμισμένοι στη μνήμη, σύμφωνα με τις απαιτήσεις της CPU για SIMD (Single Instruction - Multiple Data) εντολές. Αυτό βελτιώνει την αποδοτικότητα, επιτρέποντας στις εντολές της OpenBLAS να επεξεργάζονται τα δεδομένα ταχύτερα και πιο αποδοτικά.

Υπολογιστικό σύστημα

Operating system : Ubuntu 24.04

Processor: AMD Ryzen 5 5600H, 3301 MHz, 6 Cores, 12 Logical Processors

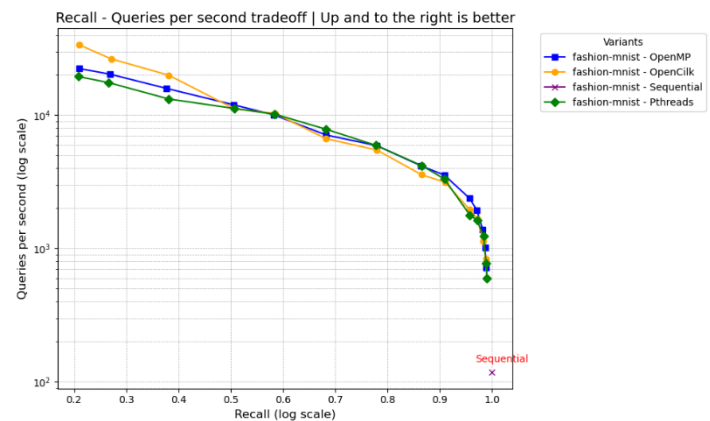
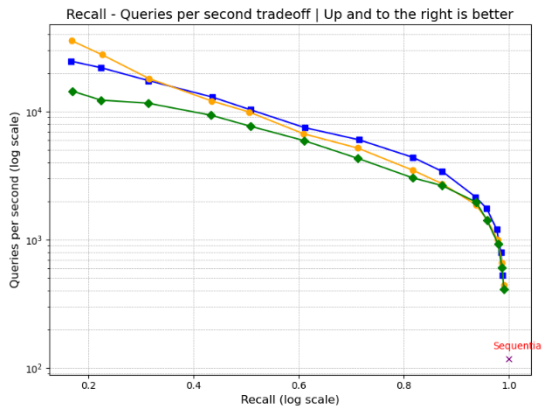
Cache size: L1 = 384KB | L2 = 3MB | L3 = 16MB

Total Physical Memory (usable) : 13,9 GB

¹ <https://github.com/erikbern/ann-benchmarks?tab=readme-ov-file#data-sets>


Benchmarks

Tradeoff Recall – Queries per second




Αρχικά παρατηρούμε πως όλες οι υλοποιήσεις έχουν παρόμοια απόδοση ιδίως για πολύ μεγάλες τιμές recall (>95%) όπου ταυτίζονται οι γραφικές παραστάσεις. Ωστόσο για μικρά recall (<50%) και υψηλούς ρυθμούς επεξεργασίας (>30000) επικρατεί η υλοποίηση με OpenCilk. Τέλος, για το dataset mnist, η OpenMP επικρατεί στην μεσαία κλίμακα (recall 60% - 90% και ρυθμός επεξεργασίας 7000-20000).

Speedup σε σχέση με τη σειριακή εκτέλεση



Το speedup είναι παρόμοιο για όλες τις υλοποιήσεις. Εδώ βλέπουμε για την OpenCilk. Η μόνη διαφορά αφορά στη διαχείριση των παραπάνω threads από αυτά του συστήματος (12). Πιο συγκεκριμένα, η OpenCilk καταφέρνει να έχει γραμμική μείωση ενώ οι υλοποιήσεις με OpenMP και Pthreads μειώνονται εκθετικά. Επιπλέον, δε παρατηρούμε βελτίωση για 14 threads όπως πιθανόν να αναμέναμε. Τέλος, αξίζει να σημειωθεί πως για ένα ικανοποιητικό recall (>80) επιτυγχάνουμε 40 φορές γρηγορότερη εκτέλεση από τη σειριακή!



Κώδικας

Ο κώδικας μπορεί να βρεθεί στο [GitHub](https://github.com/fraidakis/PDS_Ex1)² όπου θα περιέχεται ανανεωμένη έκδοση του report.

² https://github.com/fraidakis/PDS_Ex1